

1. Предобработка данных

Загружаем собранный датафрейм в среду jupyter-ноутбук. Изучим полученную структуру:

```
(94009, 7)
Index(['source', 'chain', 'year', 'author', 'rating', 'text', 'reactions'], dtype='object')
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 94009 entries, 0 to 94008
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   source      94009 non-null  object
1   chain       94009 non-null  object
2   year        93907 non-null  float64
3   author      85124 non-null  object
4   rating      94009 non-null  int64
5   text        93906 non-null  object
6   reactions   94009 non-null  int64
dtypes: float64(1), int64(2), object(4)
memory usage: 5.0+ MB
```

Рисунок 1 – Структура анализируемого датафрейма

Итак, видим, что в итоге удалось собрать 94 009 записей (отзывов). Полученный датафрейм содержит 7 столбцов: источник, название сети, год, никнейм автора, оценка, сам текст отзыва и количество реакций. Далее видим, что в сформированном датафрейме в столбцах year, author, text содержатся пропуски: в year 93 907 заполненных строк, значит 102 пропуска, в author — 85 124, значит почти 8 885 пропусков, в text — 93 906, значит 103 отзыва без текста.

В ходе предобработки мы последовательно приводим исходные тексты отзывов к единому формату, избавляясь от «шума» и сводя слова к их базовым формам. Для этого используются такие техники как:

1) Токенизация — разбивка текста на «слова-токены» (или более крупные смысловые единицы). Это позволяет перевести строку символов в список элементов, с которыми удобно работать алгоритмически.

2) POS-теггинг (Part-Of-Speech tagging) — автоматическое присвоение каждому токenu грамматической категории (существительное, прилагательное, глагол и т. д.). Понимая, какая перед нами часть речи, лемматизатор точнее выбирает нужную базовую форму слова и даёт возможность фильтровать ненужные токены (например, союзы или служебные слова).

3) Лемматизация — приведение слова к его нормальной форме: русское «красивее» меняем на «красивый», английское «running» на «run».

После этого разные формы одного слова агрегируются в одну, что уменьшает размер словаря и повышает семантическую связность данных.

4) Слияние по Левенштейну — этап, на котором мы находим пары лемм с почти идентичным написанием (обычно из-за опечаток или вариаций транслитерации) и автоматически объединяем их в более частотный вариант. Это ещё сильнее сокращает «шум» от редких ошибок ввода.

Приступим к предобработке текстов. Сначала каждая строка переводится в нижний регистр и очищается от URL-ссылок, цифр и любых символов, не относящихся к буквам русского или английского алфавита. Это позволяет избавиться от «мусора» и сконцентрироваться на лингвистическом содержании.

Далее текст разбивается на токены с помощью NLTK, после чего происходит простая детекция языка: если в строке встречается кириллический символ, мы считаем её русскоязычной и отправляем токены на морфологическую обработку `rumorphy3`, иначе — на английскую лемматизацию через WordNet и POS-теги из NLTK. В обоих случаях в выходной список попадают лишь те леммы, которые не входят в набор стоп-слов и имеют длину более двух символов — это исключает артикли, союзы, предлоги и прочие «служебные» слова, не несущие смысловой нагрузки.

Третьим этапом является агрегация «похожих» лемм на основе расстояния Левенштейна. Мы подсчитываем частоты всех лемм в корпусе, группируем слова по длине и сравниваем попарно только внутри одной длины. Если коэффициент похожести (`Levenshtein.ratio`) превышает заданный порог (например, 0.85), менее частотная форма слова «склеивается» с более употребимой, что позволяет минимизировать эффект опечаток или вариаций написания.

Наконец, результатом становится новый столбец `clean_text`, где каждый отзыв представлен как строка из лемм, разделённых пробелами. Такая структура оптимальна для дальнейшей векторизации («мешок слов», TF-IDF) и тематического моделирования, поскольку содержит только ключевые понятия без «мусорных» словоформ и повторов, а объединение похожих лемм дополнительно повышает стабильность и читаемость полученных тем.

	text	clean_text
0	Магазин сам по себе хороший, ассортимент радует...	магазин хороший ассортимент радовать заграничн...
1	Хороший ассортимент, нашла здесь марки, которых ...	хороший ассортимент найти марка который нигде ...
2	Большой магазин с хорошим ассортиментом. Вежлив...	большой магазин хороший ассортимент вежливый к...
3	Отличный магазин, покупал жене подарок не на о...	отличный магазин покупать жена подарок праздни...
4	Магазин находится в центре города, очень уютна...	магазин находится центр город очень уютный ат...

Рисунок 2 – Фрагмент датафрейма с исходными отзывами и результатом предобработки

2. Тематическое моделирование и визуализация результатов

Latent Dirichlet Allocation (LDA) — это вероятностная модель тематического моделирования текстов, которая позволяет автоматизированно выявлять скрытые «темы» в коллекции документов. По сути, LDA предполагает, что каждый документ представляет собой смесь нескольких тем в разных пропорциях, а каждая тема, в свою очередь, характеризуется распределением слов. Например, в отзывах о косметике одна тема может сильно весить слова «аромат, парфюм, нота», другая — «цена, скидка, акция», а третья — «консультант, персонал, сервис».

Математически LDA задаёт генеративный процесс: для каждой темы выбирается вектор вероятностей слов (из словаря), распределённый по Dirichlet-распределению с параметром β , далее для каждого документа выбирается вектор тем, отражающий его тематический профиль, затем для каждого слова в документе случайным образом выбирается тема согласно вектору тем, а затем слово — согласно словарному распределению этой темы.

Процесс обучения LDA-модели заключается в обратной задаче: имея документы, мы пытаемся оценить (аппроксимировать) эти скрытые распределения тем в документах и распределения слов в темах. В результате получаем: для каждого документа d вектор весов тем (какие и в каких долях темы «составляют» этот документ); для каждой темы k вектор весов слов (какие слова наиболее характерны для темы).

LDA хорошо подходит для анализа отзывов, поскольку позволяет одновременно уменьшить размерность текстового пространства, заменяя тысячи отдельных слов несколькими десятками тем, интерпретировать каждую тему через ключевые слова — и тем самым делать качественные выводы о потребительских «болях» и предпочтениях, сопоставлять документам

(отзывам) тематические профили и строить количественную аналитику (распределение тем, динамику во времени, связь с оценками и пр.).

Перейдем к реализации. Определим оптимальное количество тем для каждой сети, опираясь на метрику когерентности (c_v). Для этого сначала разбиваем каждый очищенный отзыв (`clean_text`) на список слов-лемм - получаем список списков, где каждый внутренний список соответствует одному отзыву. Затем на этой коллекции строим два важных объекта для Gensim: словарь (Dictionary) - где каждой уникальной лемме присвоен свой идентификатор и корпус (corpus) - список документов в формате «мешок слов», то есть для каждого отзыва хранится, сколько раз в нём встретилась каждая лемма. Имея эти объекты, мы обучаем несколько LDA-моделей, меняя только число тем (от 3 до 10), и для каждой вычисляем её когерентность. Такая проверка позволяет выбрать именно то количество тем, при котором слова внутри тем оказываются максимально связанными и осмысленными. В выводе увидим, что для «Золотого яблока» лучшим получилось 7 тем, для «Рив Гош» — 4, а для «Л'Этуаль» — 6.

Золотое яблоко: 10426 отзывов	Рив Гош: 10973 отзывов	Л'Этуаль: 19298 отзывов
n=3: coherence = 0.517	n=3: coherence = 0.497	n=3: coherence = 0.593
n=4: coherence = 0.528	n=4: coherence = 0.513	n=4: coherence = 0.582
n=5: coherence = 0.516	n=5: coherence = 0.488	n=5: coherence = 0.575
n=6: coherence = 0.514	n=6: coherence = 0.500	n=6: coherence = 0.598
n=7: coherence = 0.542	n=7: coherence = 0.486	n=7: coherence = 0.535
n=8: coherence = 0.528	n=8: coherence = 0.494	n=8: coherence = 0.524
n=9: coherence = 0.509	n=9: coherence = 0.510	n=9: coherence = 0.555
n=10: coherence = 0.514	n=10: coherence = 0.491	n=10: coherence = 0.538
Лучшее число тем: 7 (coherence=0.542)	Лучшее число тем: 4 (coherence=0.513)	Лучшее число тем: 6 (coherence=0.598)

Рисунок 3 – Результаты вычисления когерентности при выборе оптимального количества тем для LDA

После подбора оптимального количества тем для каждой сети, обучаем финальные LDA-модели на очищенных отзывах отдельно для «Золотого яблока», «Рив Гош» и «Л'Этуаль». Для каждой сети берём её подмножество отзывов и строим «мешок слов» — матрицу документ-термин с помощью того же CountVectorizer. Это позволяет перевести текстовые данные в числовой формат, необходимый для LDA.

Затем для каждой сети создаём и обучаем модель с найденным оптимальным числом тем. После обучения выводим топ-7 ключевых слов для каждой темы — это помогает убедиться, что темы получились чёткими и различимыми, отражающими реальные аспекты отзывов (ассортимент, цены, сервис и т. д.).

Золотое яблоко: обучаем LDA на 7 темах

Тема 1: спасибо, помочь, подобрать, покупка, довольный, прекрасный, приятный

Тема 2: цена, скидка, косметика, ассортимент, товар, хороший, акция

Тема 3: хороший, выбор, персонал, вежливый, большой, ассортимент, косметика

Тема 4: заказ, товар, доставка, деньги, карта, возврат, поддержка

Тема 5: персонал, отличный, приветливый, продукция, подсказать, вода, отношение

Тема 6: аромат, дух, парфюм, покупка, подарок, дать, пробник

Тема 7: охранник, товар, покупка, косметика, продукт, нужный, большой

Рив Гош: обучаем LDA на 4 темах

Тема 1: выбор, хороший, персонал, большой, вежливый, помочь, ассортимент

Тема 2: косметика, скидка, ассортимент, акция, хороший, цена, товар

Тема 3: аромат, спасибо, помочь, сотрудник, большой, подобрать, парфюм

Тема 4: товар, заказ, косметика, карта, покупка, деньги, отношение

Лэтуаль: обучаем LDA на 6 темах

Тема 1: заказ, товар, интернет, ждать, деньги, приложение, доставка

Тема 2: персонал, помочь, выбор, хороший, вежливый, спасибо, приятный

Тема 3: тестер, охранник, дух, товар, аромат, большой, парфюм

Тема 4: ассортимент, выбор, большой, хороший, косметика, маленький, товар

Тема 5: цена, хороший, ценник, товар, акция, скидка, вода

Тема 6: карта, охранник, отношение, персонал, сотрудник, кассир, товар

Рисунок 4 – Ключевые слова по темам для каждой сети

Далее подготовим и отобразим интерактивные дашборды PyLDAvis для каждой из трёх сетей, чтобы наглядно исследовать структуру тем и их взаимное расположение в двумерном пространстве. Каждая визуализация показывает: Intertopic Distance Map (двумерная проекция тем, где расстояние между кружками отражает схожесть распределений слов) и Top-N Most Salient Terms для выбранной темы, с возможностью регулировки метрики релевантности (λ). Такая интерактивная карта позволяет быстро оценить, какие темы слишком перекрываются (и требуют слияния), какие, наоборот, нарочито изолированы, а также посмотреть ключевые слова каждой темы в контексте всего корпуса. В отчёте эти дашборды служат инструментом для глубокой проверки качества модельного разбиения и для презентации результатов заинтересованным сторонам.

На получившемся дашборде сети «Золотое Яблоко» видим семь кружков, два из которых (Тема 1 и Тема 6) накладываются друг на друга, указывая на избыточность и схожесть их содержимого.




Рисунок 5 – Дашборд тем по сети «Золотое яблоко»

Для «Рив Гош» все четыре темы хорошо разделены по расстоянию, перекрытия не наблюдаются, что говорит о том, что в отзывах «Рив Гош» естественно сосуществуют четыре относительно независимых направления обсуждения: ассортимент, ценовые вопросы, подбор ароматов и логистика заказов.




Рисунок 6 – Дашборд тем по сети «Рив Гош»

Полученные темы в отзывах у «Л'Этуаль» также хорошо делимы. Такое расположение подтверждает, что отзывы чётко дифференцируются и не смешиваются друг с другом до объединения тем.




Рисунок 7 – Дашборд тем по сети «Лэтуаль»

Далее проводим финальную стадию тематического анализа, в которой обучаем окончательные LDA-модели для каждой из трёх сетей уже с утверждённым числом тем и сразу же связываем результаты с удобочитаемыми метками. Вначале обновляем словарь `topic_names`, где для «Золотого яблока» объединяем темы 1 и 6. В результате на обновлённой карте тем для видим уже шесть более чётко различимых круга, переход от 7 к 6 темам оправдан.




Рисунок 8 – Дашборд с отредактированным количеством тем по сети «Золотое яблоко»

Затем для каждой сети берем очищенные тексты из столбца `clean_text`, векторизуем их и обучаем модель с тем числом тем, которое дало наилучший coherence на предыдущем этапе. После этого получаем матрицу «документ–

тема» и присваиваем каждому отзыву номер темы с наибольшей вероятностью.

Специально «Золотого яблока» дополняем шаг разметки: все отзывы, которым LDA присвоила тему 6, переназначались в тему 1. Далее преобразовываем номера тем в понятные текстовые лейблы через обновлённый словарь `topic_names`. И, наконец, группируем разметку по тройке полей (`chain`, `topic`, `topic_label`) и рассчитываем для каждой темы ключевые метрики: число и долю отзывов, средний рейтинг, среднее число реакций и диапазон годов публикаций. Все результаты были объединены в единый датафрейм `all_stats_df`, готовый к визуализации и дальнейшему анализу.

	chain	topic	topic_label	n_reviews	pct_reviews	avg_rating	avg_reactions	first_year	last_year
0	Золотое яблоко	1	Подбор продукции и благодарности	3017	28.937272	3.646006	2.825655	2011.0	2025.0
1	Золотое яблоко	2	Цены и акции	1726	16.554767	4.205098	3.723059	2010.0	2025.0
2	Золотое яблоко	3	Ассортимент	2681	25.714560	4.809772	2.190974	2014.0	2025.0
3	Золотое яблоко	4	Онлайн-заказ и возвраты	1050	10.070976	1.612381	2.952381	2011.0	2025.0
4	Золотое яблоко	5	Отношения с персоналом	807	7.740265	3.890954	2.332094	2015.0	2025.0
5	Золотое яблоко	7	Охрана и контроль	1145	10.982160	2.910917	3.459389	2015.0	2025.0
6	Рив Гош	1	Ассортимент и сервис	3255	29.663720	4.638402	2.087250	2011.0	2025.0
7	Рив Гош	2	Цены и скидки	2310	21.051672	4.265801	2.735931	2010.0	2025.0
8	Рив Гош	3	Ароматы и подбор	2836	25.845257	3.518688	2.741890	2011.0	2025.0
9	Рив Гош	4	Покупка и возвраты	2572	23.439351	2.007776	2.837481	2011.0	2025.0
10	Лэтуаль	1	Онлайн-сервис	2076	10.757591	1.981696	2.264933	2016.0	2025.0
11	Лэтуаль	2	Консультации и помощь	4707	24.391129	4.839813	1.768642	2015.0	2025.0
12	Лэтуаль	3	Тестеры и охрана	3810	19.742979	1.987927	3.056430	2015.0	2025.0
13	Лэтуаль	4	Ассортимент	4285	22.204374	4.369195	2.180163	2018.0	2025.0
14	Лэтуаль	5	Цены и акции	2160	11.192870	3.460648	2.335648	2015.0	2025.0
15	Лэтуаль	6	Оплата и кассы	2260	11.711058	2.538938	2.742035	2015.0	2025.0

По итогам объединённого анализа тем и расчёта ключевых метрик получилась следующая картина:

1) «Золотое яблоко»

Наиболее распространённой темой (около 29 % всех отзывов) стала «Подбор продукции и благодарности» — объединённая Тема 1, куда вошли все отзывы о помощи консультантов и о впечатлениях потребителя от консультаций. Средний рейтинг относительно высок (3.65), а число реакций (около 2.8) говорит о высоком, но не максимальном вовлечении.

Второй по объёму блок (около 26 %) – «Ассортимент» (Тема 3) – получил очень высокую оценку (4.81), но реакции пользователей были ниже (2.2). Тема 2 («Цены и акции», около 16.6 %, рейтинг около 4.21, реакции около 3.72)

показывает высокий интерес аудитории к выгодным предложениям и живой отклик на них. В то же время «Онлайн-заказ и возвраты» (Тема 4, 10 % отзывов) и «Охрана и контроль» (Тема 7, 11 %) — два наиболее проблемных направления с низкими средними оценками (1.61 и 2.91 соответственно) и заметным числом реакции (3.0–3.5): пользователи активно комментируют сложности с интернет-сервисом и охраной в магазине. Наименее представленной, но всё же значимой оказалась тема «Отношения с персоналом» (Тема 5, 7.7 %, рейтинг около 3.89), демонстрирующая хороший опыт взаимодействия с сотрудниками.

2) «Рив Гош»

Здесь лидер – «Ассортимент и сервис» (Тема 1, около 29.7 % отзывов) – получает высокую оценку (около 4.64), однако с относительно низким числом реакций (2.1), что говорит о позитивном, но «спокойном» обсуждении. «Ароматы и подбор» (Тема 3, 25.8 %) набирает более скромный рейтинг (3.52) и чуть более высокую вовлечённость (2.74), указывая на неоднозначные отзывы о подборе парфюмерии. Темы «Цены и скидки» (Тема 2, около 21.1 %, рейтинг около 4.27, реакции около 2.74) и «Покупка и возвраты» (Тема 4, около 23.4 %, рейтинг 2.01, реакции 2.84) демонстрируют две грани пользовательского опыта: одни довольны выгодами, другие жалуются на логистику и послепродажную поддержку. В целом у «Рив Гош» разброс оценок по темам невелик, но наиболее слабым местом остаётся процесс оформления и возврата заказа.

3) «Л'Этуаль»

В «Л'Этуаль» самым большим по объёму оказался блок «Консультации и помощь» (Тема 2, около 24.4 %), который показывает впечатляющий средний рейтинг (4.84) и наименьшую вовлечённость (1.77), что говорит о «тихом» положительном фидбэке, не порождающем много обсуждений. «Ассортимент» (Тема 4, около 22.2 %, рейтинг 4.37, реакции 2.18) тоже оценивается очень высоко, но «кричащая» тема «Тестеры и охрана» (Тема 3, около 19.7 %) получила низкий средний балл (1.99) и, наоборот, высокий отклик (3.06), что отражает недовольство клиентов политикой контроля пробников. Остальные темы — «Цены и акции» (Тема 5, 11.2 %, рейтинг 3.46), «Оплата и кассы» (Тема 6, 11.7 %, рейтинг 2.54) и «Онлайн-сервис» (Тема 1, 10.8 %, рейтинг 1.98) — демонстрируют средние оценки и средний уровень вовлечения (2.2–2.7), указывая на сбалансированный, но неоднозначный опыт покупок как в офлайне, так и в интернете.

Таким образом, во всех трёх сетях ассортимент и консультации оказываются главными драйверами лояльности и положительных отзывов, тогда как онлайн-заказ/возвраты формируют наибольшее количество негативных комментариев и реакций. Тема цены стабильно получают высокие оценки и заметный социальный отклик. На основе этих данных бизнесу стоит сконцентрироваться на улучшении интернет-сервисов и логистике.

Визуализируем результаты, сформируем три серии графиков по трем сетям: доля отзывов по темам, средний рейтинг по темам, среднее число реакций. После объединения тем «Подбор продукции и благодарности» (Тема 1) превратилась в крупнейший кластер отзывов «Золотого яблока» — почти треть всех откликов ($\approx 29\%$). Далее следуют «Ассортимент» ($\approx 26\%$) и «Цены и акции» ($\approx 16,6\%$). Тема «Онлайн-заказ и возвраты» удерживает $\approx 10\%$, а «Охрана и контроль» — $\approx 11\%$. У «Рив Гош» лидирует «Ассортимент и сервис» ($\approx 29,7\%$), затем «Ароматы и подбор» ($\approx 25,8\%$), «Покупка и возвраты» ($\approx 23,4\%$) и «Цены и скидки» ($\approx 21,1\%$). В «Л'Этуаль» основное внимание — к «Консультациям и помощи» ($\approx 24,4\%$) и «Ассортименту» ($\approx 22,2\%$), дальше идут «Тестеры и охрана» ($\approx 19,7\%$), «Цены и акции» ($\approx 11,2\%$), «Оплата и кассы» ($\approx 11,7\%$) и «Онлайн-сервис» ($\approx 10,8\%$).




Рисунок 9 – Распределение доли отзывов по темам

В «Золотом яблоке» самую высокую оценку получили «Ассортимент» ($\approx 4,81$) и «Цены и акции» ($\approx 4,21$). «Подбор продукции и благодарности» набрала $\approx 3,65$, а «Отношения с персоналом» — $\approx 3,89$. Низкие баллы у «Охраны и контроля» ($\approx 2,91$) и особенно у «Онлайн-заказа и возвратов» ($\approx 1,61$). Для «Рив Гош» «Ассортимент и сервис» оценивают в среднем на $\approx 4,64$, «Цены и скидки» — $\approx 4,27$, «Ароматы и подбор» — $\approx 3,52$, «Покупка и возвраты» — лишь $\approx 2,01$. В «Л'Этуаль» «Консультации и помощь» получают высший балл $\approx 4,84$, «Ассортимент» $\approx 4,37$, «Цены и акции» $\approx 3,46$.




Рисунок 10 – Распределение среднего рейтинга отзывов по темам

В «Золотом яблоке» наибольший социальный резонанс вызывают «Цены и акции» ($\approx 3,72$) и «Охрана и контроль» ($\approx 3,46$), а меньше всего — «Ассортимент» ($\approx 2,19$). Объединённая Тема 1 набирает $\approx 2,83$, «Онлайн-заказ и возвраты» — $\approx 2,95$, «Отношения с персоналом» — $\approx 2,33$. Для «Рив Гош» наиболее активно комментируют и лайкают «Покупка и возвраты» и «Ароматы и подбор» ($\approx 2,84$ – $2,74$), чуть меньше — «Цены и скидки» ($\approx 2,74$) и «Ассортимент и сервис» ($\approx 2,09$). В «Л'Этуаль» максимальный отклик у «Тестеры и охрана» ($\approx 3,06$) и «Оплата и кассы» ($\approx 2,74$), средние показатели у «Ассортимента» и «Цен» ($\approx 2,18$ – $2,34$), а «Консультации и помощь» и «Онлайн-сервис» получают самый скромный фидбэк ($\sim 1,77$ – $2,26$).




Рисунок 11 – Распределение реакций на отзывы по темам